

Analítica de Negocios

CHALLENGE 2

IMDb (Internet Movie Database) es una base de datos en línea con información detallada sobre películas, series de televisión, actores, directores, bandas sonoras y más. Es una fuente popular para los amantes del cine y televisión que buscan información sobre títulos, tráilers, reseñas, noticias y mucho más.

Se desea pronosticar la polaridad de las reseña de los usuarios y con esto conocer de una manera más precisa cuales fueron los sentimientos percibidos por la audiencia, tomando como punto de partida algunos datos cada una de las cintas.

Limpieza de datos

Para el correcto desarrollo del *Challenge* es necesario hacer la preparación y limpieza de los datos, para lo cual se recomienda los siguientes pasos:

- Elimina las filas con vacíos y reinicia el índice de las filas.
- Convierte las columnas 'movie', y 'username' a variables categóricas.
- La variable 'date' está como *string*. Conviértela a fecha.

Análisis de sentimientos

Para el Análisis de Sentimientos implementa un modelo (*Sentiment Intensity Analyzer*) para obtener las polaridades de cada una de las reseñas de los usuarios, los cuales se encuentran contenidos en la columna 'review'¹. Luego de obtener estas polaridades añádelas al dataset original como una nueva columna que se llame 'polarity'. A partir de los resultados obtenidos de la implementación del modelo SIA realiza los siguientes análisis:

- Imprime la reseña con la mayor polaridad y analiza: ¿Cuál crees que es la parte de la reseña que genera un *compound* más positivo?
- Imprime la reseña con la menor polaridad y analiza: ¿Cuál crees que es la parte de la reseña que genera un *compound* más negativo?
- Grafica las polaridades en un histograma² y responde: ¿Cuál es el volumen (cantidad) de las polaridades positivas y de las negativas? ¿Cómo se ve la polaridad neutra 0.0 en el gráfico?
- Realiza un grafico polar tomando como punto de partida las polaridades de las

¹ Recuerda que el texto ya viene en Inglés, por lo que no es necesario traducirlo.

² Se recomienda el gráfico `sns.displot()` de la librería `seaborn`.

reseñas que dio la audiencia a las películas estrenadas en los años 2011, 2015, 2019 y 2020, y responde:

- ¿Cuál fue el año en el que la audiencia se sintió más *fascinada*?
- ¿Cuál fue el año en el que más aumentaron los sentimientos positivos?
- ¿Cuál fue el año en el que más aumentaron los sentimientos negativos?
- ¿Cuál fue el año en el que hubo más sentimientos positivos?
- ¿Cuál fue el año en el que hubo más sentimientos negativos?
-

Para la construcción de estos gráficos considera la siguiente escala PANAS-t, cuyos significados se encuentran en la hoja 'Panas-t' del dataset

['Molesto', 'Irritado', 'Decepcionado', 'Indiferente', 'Neutral', 'Tranquilo', 'Interesado', 'Satisfecho', 'Inspirado', 'Fascinado']

Modelos Neuronales

Finalmente, para lograr el objetivo que nos plantea la compañía, que es el de pronosticar el nivel de satisfacción de un cliente prediciendo la polaridad que tendría una tentativa reseña, entrenaremos un modelo neuronal que permita predecir el sentimiento que tendrá el cliente sobre el servicio, partiendo del supuesto que las siguientes variables se consideran independientes:

['year', 'movie', 'rating', 'helpful', 'total', 'username']

Nota: Recuerda normalizar las variables independientes usando el valor máximo de cada variable; y la variable dependiente aplicando la fórmula vista en clase:

$$y_{d_{normalizada}} = \frac{y_d - \min(y_d)}{\max(y_d) - \min(y_d)}$$

Implementa dos modelos neuronales, un ADALINE y un MADALINE, este último con una capa oculta de 10 neuronas. La capa de salida debe tener una función de activación sigmoide y las demás deben tener una función de activación lineal. Para ambos modelos considera un entrenamiento inicial con 300 epoch y un batch_size equivalente al 10% de los datos después de haber sido limpiados.

Para cada uno de los modelos responde lo siguiente:

- ¿Cuántos parámetros entrenables posee?
- ¿Cuál es la correlación obtenida de cada modelo?
- ¿Cuál es el epoch en el que la función de pérdida (*loss*) se estabiliza?

- ¿Consideraría aumentar o disminuir el batch_size? Explica
- ¿Consideraría aumentar a disminuir las neuronas en la capa oculta o el número de capas ocultas? Explica la implicación de cada una de ellas.
- Indica la suma del producto de $w_{ji} * C_j$ de cada una de las seis variables de entrada. Analiza en términos generales qué significa y cual es la variable que presenta el mayor valor.

Finalmente analiza:

¿Se logró el objetivo propuesto por la compañía?

¡Mucha Suerte!

Referencias:

Identifying movie genre compositions using neural networks and introducing GenRec- a recommender system based on audience genre perception.

Aditya Pal; Abhilash Barigidad; Abhijit Mustafi.

IEEE, 2020

PANAS-t

- **Fascinado:** El espectador expresa asombro y admiración. Las reseñas reflejan que la película dejó una fuerte impresión positiva, destacando su originalidad, profundidad o calidad estética.
- **Inspirado:** La película provocó una reacción emocional significativa, motivando reflexiones personales o deseos de acción. Los comentarios suelen ser emotivos y resaltan el impacto del mensaje o la historia.
- **Satisfecho:** La película cumplió con lo esperado. El espectador se siente conforme con la experiencia general, señalando que disfrutó del contenido, aunque no necesariamente lo considere extraordinario.
- **Interesado:** El espectador se mantuvo atento y comprometido con la película. Las reseñas destacan que la historia logró captar su atención, con frases como “me enganchó” o “quería saber qué pasaba al final”.
- **Tranquilo:** El tono del comentario indica que la película generó una experiencia serena, sin emociones intensas. El espectador se sintió a gusto viendo la película, aunque no haya sido especialmente impactante.
- **Neutral:** El espectador adopta una postura equilibrada. Reconoce tanto aspectos positivos como negativos, sin dejarse llevar por una emoción predominante. Las reseñas tienden a ser analíticas o comparativas.
- **Indiferente:** La película no generó impacto emocional significativo. Los comentarios suelen ser breves o poco comprometidos, señalando que la experiencia fue olvidable o irrelevante, sin provocar interés o rechazo.
- **Decepcionado:** El espectador tenía expectativas altas que no fueron cumplidas. Las reseñas reflejan una sensación de pérdida o insatisfacción, con expresiones como “esperaba mucho más” o “me dejó con un vacío”.
- **Irritado:** Comentarios que denotan una molestia persistente, aunque menos intensa que el enojo. El espectador se siente fastidiado por elementos repetitivos, decisiones narrativas poco acertadas o situaciones que le resultaron desagradables.
- **Molesto:** El espectador expresa un fuerte desagrado o incomodidad frente a aspectos de la película como el guion, las actuaciones o la dirección. Las reseñas reflejan frustración o rechazo directo, con frases como “no soporto esta película” o “me pareció insoportable”.